

Задача А3

Зарина Рамазанова

SET 5, февраль 2025

Этап 1

Реализация классов HashFuncGen и RandomStreamGen доступны в репозитории: https://github.com/sunflowerthu/ADS_A3_SET5

Этап 2

Реализация алгоритма HyperLogLog доступна в том же репозитории. Для реализации экспериментально был подобран параметр B . Для оценки влияния количества регистров были рассмотрены значения 6, 8, 10, 12. Для каждого размера потока и каждого значения параметра B генерировалось 30 независимых потоков данных. Для каждого потока и каждого шага вычислялись:

- точное число различных элементов;
- оценка алгоритма HyperLogLog.

По всем потокам вычислялись выборочные статистики:

- математическое ожидание оценки;
- стандартное отклонение.

Результаты экспериментов сохранялись в формате CSV, что позволило выполнить последующую визуализацию с использованием языка Python. Экспериментально установлено, что увеличение параметра B приводит к уменьшению стандартного отклонения оценки, что согласуется с теоретической оценкой ошибки алгоритма HyperLogLog. При малых значениях B (например, $B = 6$) наблюдается заметная вариативность оценки, тогда как при больших значениях B (например, $B = 12$) точность возрастает, но увеличивается объём используемой памяти. На основании проведённых экспериментов был выбран параметр $B = 12$ именно из-за точности. Графики визуализации результатов для всех значений B можно увидеть в репозитории в файле *ADSA3SET5.ipynb*

График №1 и График №2 этих этапов также представлены в этом файле.

Этап 3

Для каждого значения параметра B и размера потока были построены статистики оценки количества уникальных элементов N_t . Сравнение среднего значения оценки с точным числом уникальных элементов показало, что среднее значение близко к истинному, что подтверждает теоретическое свойство алгоритма, а экспериментально вычисленные относительные ошибки укладываются в рамки теоретической оценки дисперсии алгоритма: $\sigma_{theor} \approx \frac{1.04}{\sqrt{2B}}$ и при поправке на малые размеры потоков $\sigma_{theor} \approx \frac{1.32}{\sqrt{2B}}$ для консервативной оценки. Построенные графики показывают, что для всех проверенных B фактические ошибки находятся в пределах $\pm\sigma$ и хорошо согласуются с указанными теоретическими пределами.

Стабильность оценок была проверена через стандартное отклонение по 30 независимым потокам данных. Наблюдения: Для малых B ($B = 6$) стандартное отклонение относительно велико и может достигать нескольких процентов от истинного значения. При $B = 8$ дисперсия заметно уменьшается, область неопределённости сужается, оценки становятся более стабильными. Для $B = 10$ и 12 дисперсия ещё ниже, однако выигрыш в точности начинает компенсироваться увеличением памяти. Таким образом, стабильность оценки прямо зависит от числа регистров и согласуется с теорией.

В формуле оценки HyperLogLog используется эмпирическая константа α_m , корректирующая смещение при небольших значениях m . В экспериментах была использована стандартная константа: $\alpha_m =$

$$\begin{cases} 0.673 & m = 16 \\ 0.697 & m = 32 \\ 0.709 & m = 64 \\ \frac{0.7213}{1 + \frac{1.079}{m}} & m > 64 \end{cases}$$

Анализ показал: Для выбранных потоков и B константа корректно компенсирует смещение, средняя оценка почти совпадает с точным числом F_0^t . Эксперименты подтвердили, что использование стандартных констант α_m обеспечивает баланс между точностью оценки и сложностью вычислений. Попытки изменения константы приводят либо к небольшой систематической погрешности, либо незначительно влияют на дисперсию, что делает стандартные значения оптимальными для практических потоков.

Точность алгоритма соответствует теоретическим прогнозам: ошибки находятся в пределах $\sigma \sim 1.04/\sqrt{2^B}$ и при консервативной оценке $\sigma \sim 1.32/\sqrt{2^B}$. Стабильность оценки повышается с увеличением B , что подтверждается уменьшением стандартного отклонения по повторным потокам. Эффективность констант α_m подтверждена экспериментально: они корректируют смещение и позволяют получать оценки, близкие к точным значениям, без необходимости подгонки под конкретные данные. Таким образом, стандартный алгоритм HyperLogLog демонстрирует высокую точность и стабильность при разумном выборе числа регистров B , что делает его эффективным инструментом для потокового подсчёта уникальных элементов.

Прочие данные

Ссылка на публичный репозиторий: https://github.com/sunflowerthu/ADS_A3_SET5